École Nationale de Commerce
et de Gestion de Settat
المدرسة الوطنية للتجارة والتسيير بسطات

PROJET F3

PRÉVISION DE L'INFLATION

Analyse économétrique et comparaison de modèles d'apprentissage automatique

Problématique : le chômage et le taux directeur permettent-ils d'anticiper l'inflation américaine à un horizon de douze mois ?



Réalisé par :
Ibrahim El-Merzouki
El Hacham Rachid

Encadré par :
M. Abderrahim Larhlimi

Établissement :
ENCG Settat

Année universitaire :
2026 – 2027

Données :
Federal Reserve Economic Data (FRED)

Sommaire

Résumé exécutif **2**
Principaux repères . . . 2

1. Introduction et problématique **2**
1.1. Question de recherche . . . 3
1.2. Démarche retenue . . . 3

2. Cadre conceptuel et choix des variables **3**
2.1. Mesurer l'inflation . . . 3
2.2. Rôle potentiel du chômage . . . 3
2.3. Rôle potentiel du taux directeur . . . 4
2.4. Pourquoi utiliser des retards ? . . . 4

3. Présentation et préparation des données **4**
3.1. Statistiques descriptives . . . 5

4. Analyse exploratoire et visualisation **5**

4.1. Dynamique de l'inflation et corrélations **7**

5. Méthodologie de modélisation **8**
5.1. Variable cible et variables explicatives . . . 8
5.2. Modèles comparés . . . 8
5.3. Validation et métriques . . . 8

6. Résultats et comparaison des performances **8**

6.1. Lecture des prévisions et des erreurs **10**

7. Importance des variables et interprétation **11**
7.1. Principaux enseignements . . . 11

8. Discussion économique : réponse à la problématique **12**
8.1. Résultats par sous-période . . . 12
8.2. Réponse indirecte . . . 12

9. Limites méthodologiques et pistes d'amélioration **12**
9.1. Révisions des données et look-ahead bias . . . 13
9.2. Vérification du calendrier mensuel . . . 13
9.3. Autres limites . . . 13
9.4. Améliorations possibles . . . 14

10. Conclusion générale **14**
Références et sources de données . . . 14
Annexe — Paramètres principaux du notebook . . . 15

Résumé exécutif

Ce rapport étudie la capacité de deux indicateurs macroéconomiques — le taux de chômage et le taux effectif des fonds fédéraux — à contribuer à la prévision de l'inflation américaine à douze mois. L'analyse s'appuie sur trois séries mensuelles de FRED : l'indice des prix à la consommation (CPIAUCSL), le taux de chômage (UNRATE) et le taux des fonds fédéraux (FEDFUNDS).

L'inflation est calculée comme la variation en pourcentage du CPI sur douze mois. À chaque date d'origine t, les variables explicatives sont les valeurs courantes et retardées de l'inflation, du chômage et du taux directeur ; la cible est l'inflation observée douze mois plus tard. Trois stratégies sont comparées : une prévision naïve fondée sur la dernière valeur connue, une régression Ridge et un modèle Gradient Boosting.

Sur l'échantillon test chronologique, la référence naïve obtient un RMSE de 2,093 points, contre 2,649 pour Ridge et 2,766 pour Gradient Boosting. Les modèles plus complexes ne font donc pas mieux que la persistance de l'inflation dans cette configuration. L'importance par permutation du Gradient Boosting fait ressortir principalement le chômage retardé de douze mois, mais plusieurs variables présentent une importance proche de zéro ou négative.

Principaux repères

Élément	Résultat
Période commune des séries	Juillet 1954 – septembre 2026
Observations après fusion complète	866
Observations modélisables	830
Découpage temporel	664 entraînement / 166 test
Meilleur RMSE test	Baseline : 2,093
Conclusion synthétique	Aucune amélioration hors échantillon des modèles ML par rapport à la baseline

Ces résultats ne démontrent pas que le chômage et le taux directeur sont économiquement inutiles. Ils indiquent plus précisément que, dans les spécifications, les retards et la période retenus, leur combinaison avec les retards d'inflation n'a pas permis de réduire l'erreur de prévision par rapport à une règle de persistance.

1. Introduction et problématique

L'inflation occupe une place centrale dans l'analyse macroéconomique. Elle affecte le pouvoir d'achat des ménages, les coûts des entreprises, les décisions d'investissement et les conditions de financement. Pour les autorités monétaires, anticiper son évolution est essentiel afin d'ajuster les instruments de politique économique. Pour les entreprises et les investisseurs, une prévision de l'inflation aide à apprécier l'évolution des coûts, des prix de vente et des taux d'intérêt réels.

L'inflation ne dépend pas d'un seul facteur. Elle peut être influencée par la demande globale, les coûts de production, les prix de l'énergie et des matières premières, les anticipations, les conditions du marché du travail et la politique monétaire. Le présent projet se concentre sur deux indicateurs disponibles mensuellement : le chômage, qui renseigne sur la situation du marché du travail, et le taux directeur, qui reflète l'orientation de la politique monétaire.

1.1. Question de recherche

Le projet cherche à déterminer si les observations passées du taux de chômage et du taux des fonds fédéraux améliorent la prévision de l'inflation annuelle américaine à un horizon de douze mois, au-delà de l'information contenue dans les valeurs passées de l'inflation.

1.2. Démarche retenue

- Constituer une base mensuelle commune à partir des trois séries FRED.
- Calculer l'inflation annuelle à partir de l'indice CPI.
- Construire une cible décalée de douze mois et des variables retardées.
- Comparer une référence naïve, Ridge et Gradient Boosting.
- Évaluer les prévisions par RMSE et MAE sur une période test chronologiquement postérieure.
- Interpréter l'importance des variables et discuter les limites, notamment les révisions des données.

La réponse à la problématique sera formulée à partir des résultats observés, sans confondre association statistique, capacité prédictive et causalité.

2. Cadre conceptuel et choix des variables

2.1. Mesurer l'inflation

Le CPIAUCSL est un indice de niveau des prix à la consommation. Il ne représente pas directement un taux d'inflation. Pour mesurer la variation annuelle des prix, le projet calcule :

$$Inflation(t) = [(CPI(t) \,/\, CPI(t-12)) - 1] \times 100$$

Cette mesure compare le niveau du CPI à celui observé douze mois auparavant. Elle est exprimée en pourcentage. Une inflation positive signifie que le niveau général des prix est supérieur à celui de l'année précédente ; une inflation négative correspond à une baisse du niveau de l'indice sur cette période.

2.2. Rôle potentiel du chômage

Le taux de chômage peut renseigner sur les tensions du marché du travail. Un marché du travail tendu peut s'accompagner de pressions salariales et soutenir la demande, tandis qu'une hausse du chômage peut signaler un ralentissement de l'activité. Toutefois, le lien entre chômage et

inflation n'est ni mécanique ni constant : il peut varier selon les périodes, les chocs d'offre et les anticipations.

2.3. Rôle potentiel du taux directeur

Le taux effectif des fonds fédéraux est un indicateur de l'orientation monétaire américaine. Un relèvement des taux vise généralement à freiner les conditions de financement et la demande, avec des délais de transmission. Il est donc possible que ses effets sur l'inflation apparaissent progressivement. En outre, la banque centrale ajuste souvent ses taux en réaction à l'inflation anticipée ou observée : une corrélation entre taux et inflation ne signifie donc pas que le taux directeur provoque directement une hausse des prix.

2.4. Pourquoi utiliser des retards ?

Les décisions économiques et monétaires produisent leurs effets avec des délais. Le modèle utilise les valeurs courantes et les retards de 1, 3, 6 et 12 mois pour chacune des trois familles de variables. Cette construction permet de tester si l'information récente ou plus ancienne est associée à l'inflation future.

3. Présentation et préparation des données

Les données proviennent de FRED (Federal Reserve Economic Data). Les fichiers CSV transmis couvrent des périodes historiques longues, mais les trois séries ne débutent pas au même moment. La période commune commence en juillet 1954, date à laquelle la série FEDFUNDS est disponible dans le jeu utilisé.

Code	**Indicateur**	**Unité / nature**	**Lignes du fichier transmis**
CPIAUCSL	Indice des prix à la consommation	Indice, corrigé des variations saisonnières	957
UNRATE	Taux de chômage	Pourcentage	945
FEDFUNDS	Taux effectif des fonds fédéraux	Pourcentage	868

Après fusion sur la date et retrait des observations incomplètes, la base commune contient 866 observations, de July 1954 à September 2026. La construction des variations annuelles, des retards et de la cible future réduit l'échantillon exploitable à 830 observations.

Étape	**Nombre d'observations**
Base commune complète après fusion	866
Base après création des retards et de la cible	830
Entraînement (80 %)	664
Test (20 %)	166

Le découpage est chronologique : l'entraînement porte sur les dates d'origine de juillet 1956 à octobre 2011 ; le test commence en novembre 2011 et se termine en août 2025 dans le notebook. La cible du test correspond donc aux taux d'inflation observés de novembre 2012 à août 2026.

3.1. Statistiques descriptives

Variable	Moyenne	Écart-type	Minimum	Maximum
CPIAUCSL	136.29	89.34	26.71	336.30
UNRATE	5.79	1.67	3.40	14.80
FEDFUNDS	4.59	3.53	0.05	19.10
Inflation annuelle	3.63	2.74	-1.96	14.59

Les statistiques mettent en évidence une forte amplitude historique des variables, notamment du taux directeur et de l'inflation. Les moyennes calculées sur plusieurs décennies agrègent des régimes économiques très différents ; elles ne décrivent donc pas nécessairement la situation actuelle.

4. Analyse exploratoire et visualisation

L'observation des séries temporelles permet de repérer les tendances de long terme, les phases de hausse et de baisse, ainsi que les changements de régime. Le CPI présente une tendance croissante sur la longue période, tandis que le chômage et le taux directeur connaissent des cycles plus marqués.

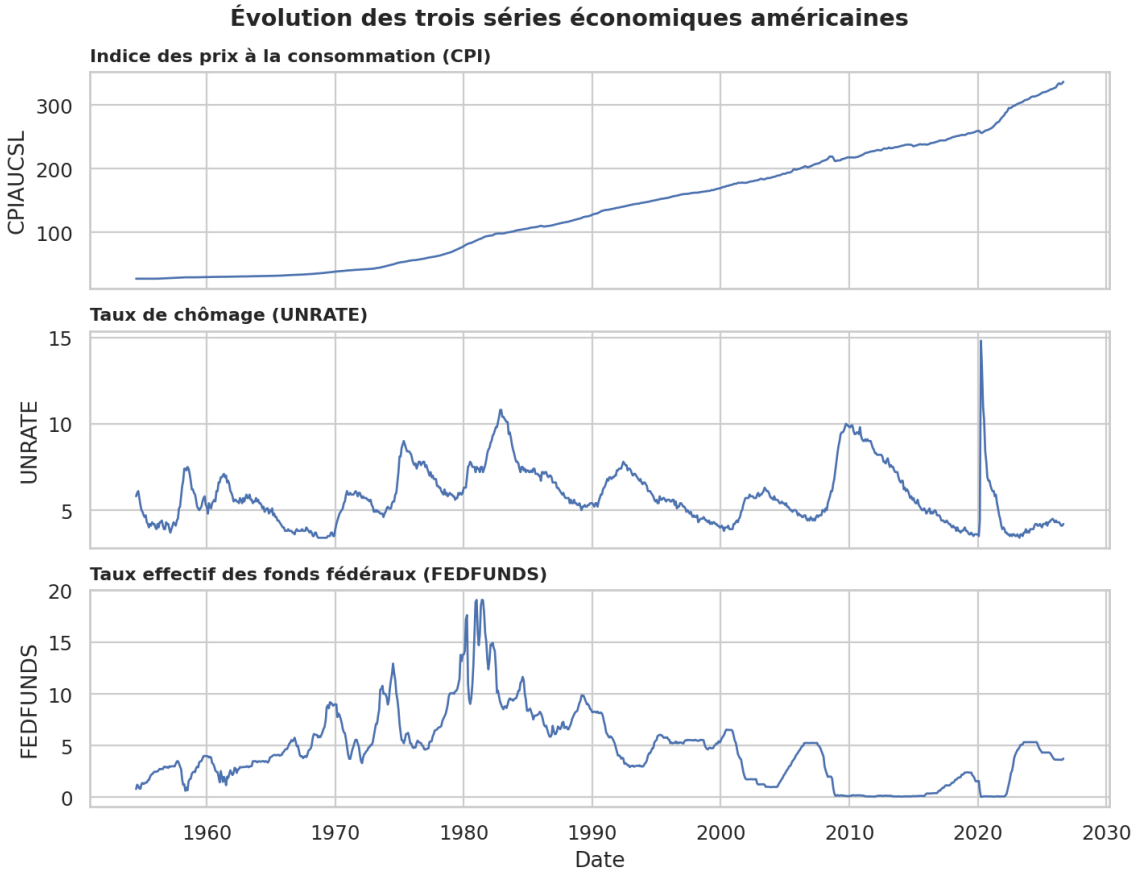


Figure 1 — Évolution des trois séries mensuelles sur leur période commune.

Le taux directeur connaît des phases de resserrement et d'assouplissement monétaires. Le chômage varie avec les cycles économiques et présente des hausses prononcées lors de périodes de ralentissement. Ces mouvements suggèrent que les indicateurs peuvent contenir de l'information conjoncturelle, mais leurs relations avec l'inflation peuvent changer dans le temps.

4.1. Dynamique de l'inflation et corrélations

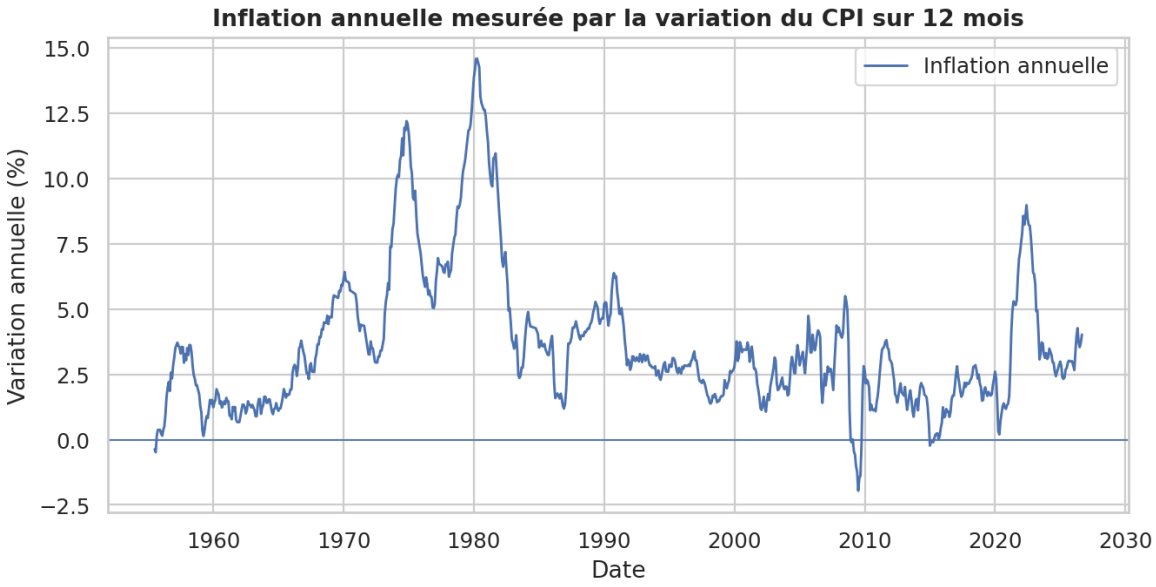


Figure 2 — Inflation annuelle calculée comme variation du CPI sur douze mois.

L'inflation annuelle connaît des fluctuations importantes. Les périodes de poussée inflationniste et de désinflation apparaissent nettement. La variation annuelle est plus informative pour la problématique que le niveau du CPI, car elle mesure le rythme de hausse des prix.

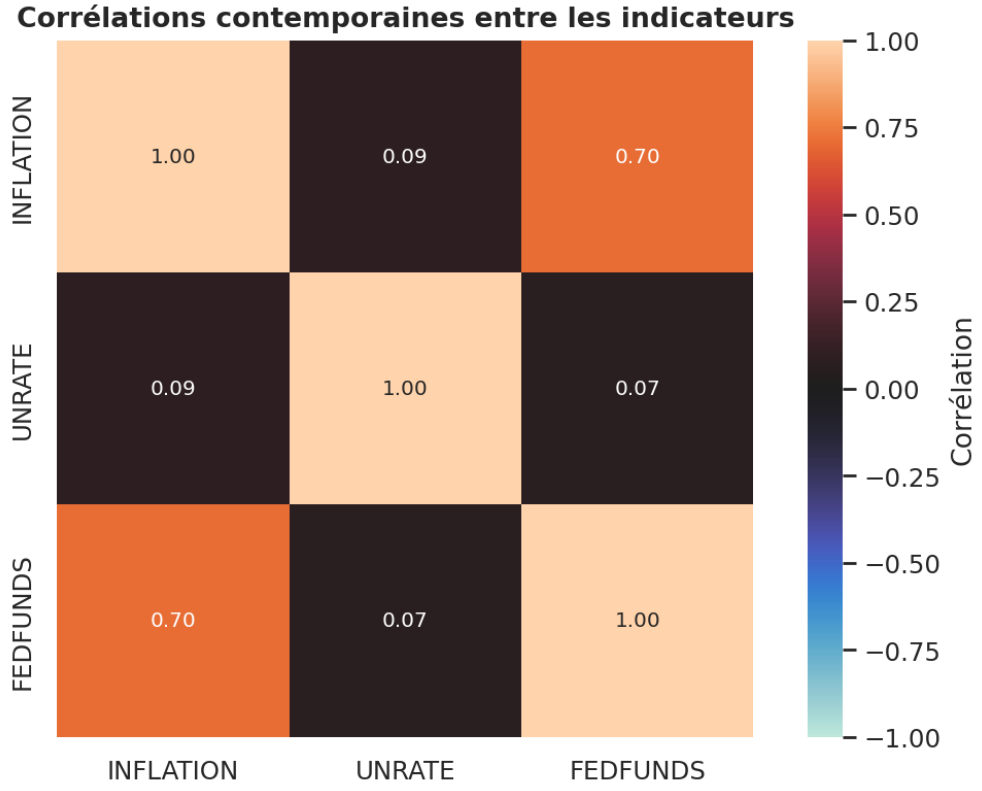


Figure 3 — Corrélations contemporaines entre inflation, chômage et taux directeur.

La corrélation contemporaine entre inflation et chômage est faible dans l'échantillon (environ 0.09), tandis que celle entre inflation et FEDFUNDS est plus élevée (environ 0.70). Cette dernière association peut notamment refléter les réactions de la politique monétaire à l'inflation. Les corrélations contemporaines ne suffisent pas à établir une capacité de prévision à douze mois.

5. Méthodologie de modélisation

5.1. Variable cible et variables explicatives

À chaque date d'origine t, la cible est l'inflation annuelle douze mois plus tard : y(t) = Inflation(t+12). Les variables explicatives comprennent l'inflation, le chômage et FEDFUNDS à la date t, puis leurs retards de 1, 3, 6 et 12 mois. Le notebook comporte ainsi quinze variables explicatives.

5.2. Modèles comparés

Modèle	Principe	Rôle dans la comparaison
Dernière valeur (baseline)	Prévoit l'inflation future avec l'inflation connue à t.	Référence de persistance simple.
Ridge	Régression linéaire avec pénalisation L2 ; alpha = 10.	Mesure une relation linéaire en limitant les coefficients trop élevés.
Gradient Boosting	200 arbres, learning_rate = 0,03, profondeur = 2.	Capture des relations non linéaires et interactions possibles.

5.3. Validation et métriques

Le jeu est divisé en respectant l'ordre chronologique : 80 % des observations pour l'entraînement et 20 % pour le test. Les modèles Ridge et Gradient Boosting sont également évalués par validation croisée temporelle à cinq plis (TimeSeriesSplit). Les pipelines intègrent l'imputation et, pour Ridge, la standardisation.

Le RMSE est la racine de l'erreur quadratique moyenne : il pénalise davantage les grandes erreurs et s'exprime dans la même unité que la cible, ici en points de pourcentage d'inflation. Le MAE mesure l'erreur absolue moyenne et est moins sensible aux erreurs extrêmes.

$$RMSE = \sqrt{[\ (1/n) \times \Sigma\ (\text{inflation observée} - \text{inflation prévue})^2\ ]}$$

Le test final est réservé à l'évaluation. Il ne sert pas à ajuster les paramètres des modèles.

6. Résultats et comparaison des performances

La validation croisée chronologique donne des RMSE moyens proches pour les deux modèles appris : environ 2,923 pour Ridge et 2,921 pour Gradient Boosting. Leur écart est très faible au

regard de la variabilité entre les plis. La baseline, évaluée sur les mêmes plis d'entraînement, présente un RMSE moyen d'environ 2,022.

Modèle	**RMSE moyen CV**	**Écart-type CV**
Baseline	2.022	0.713
Ridge	2.923	1.753
Gradient Boosting	2.921	1.290

Sur l'échantillon test, la hiérarchie est claire : la baseline obtient l'erreur la plus faible. Ridge et Gradient Boosting présentent des RMSE supérieurs, ce qui signifie qu'ils s'écartent davantage des valeurs réellement observées.

Modèle	**RMSE test**	**MAE test**
Dernière valeur (baseline)	2.093	1.474
Ridge	2.649	1.942
Gradient Boosting	2.766	1.911

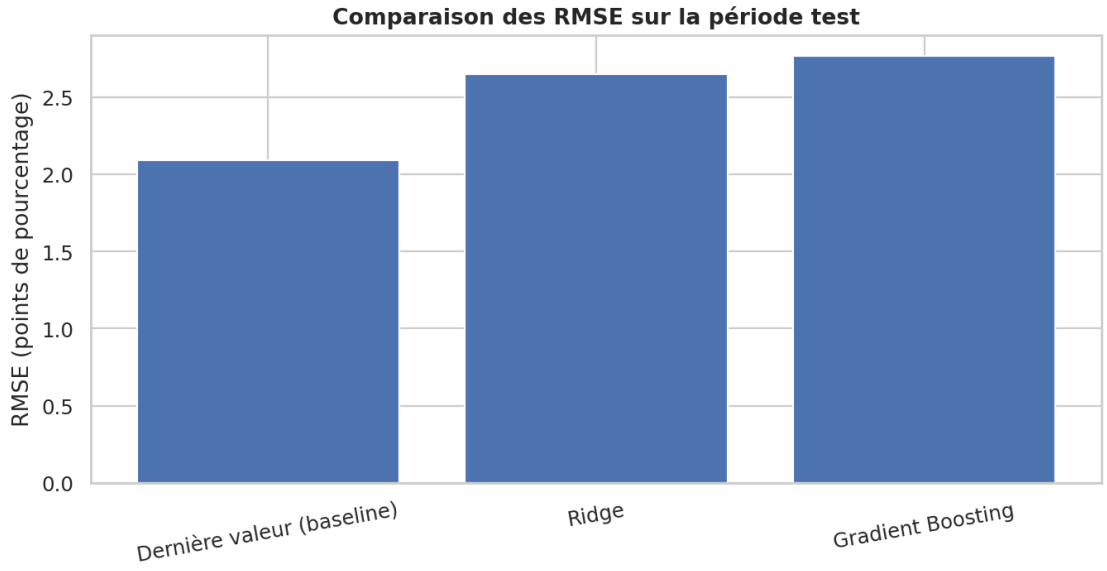


Figure 4 — Comparaison des RMSE sur l'échantillon test (plus bas = meilleure prévision).

6.1. Lecture des prévisions et des erreurs

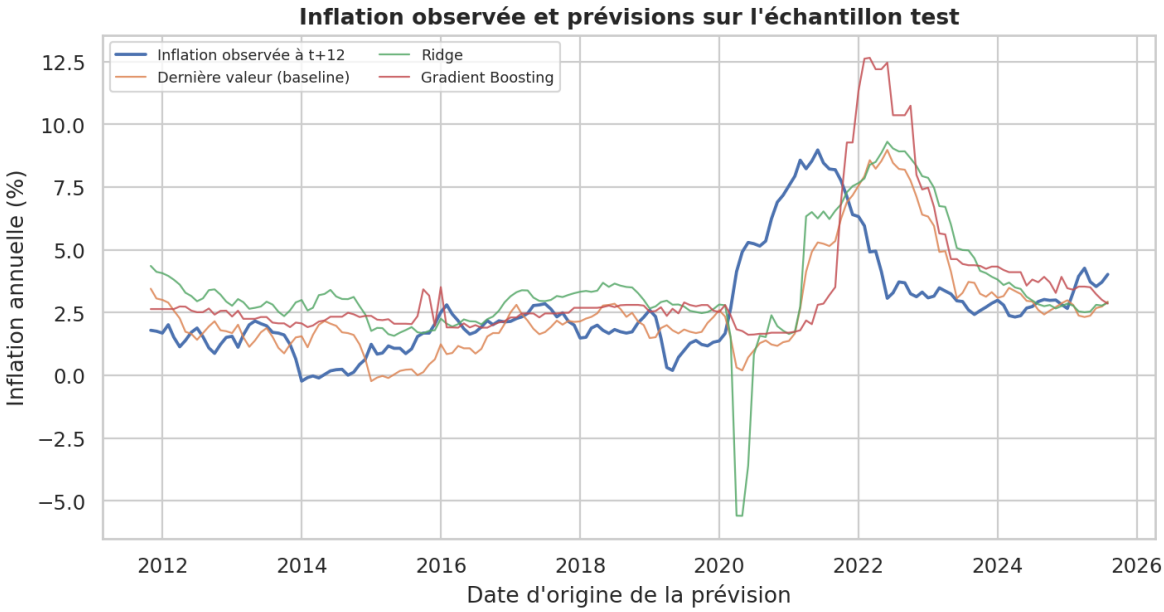


Figure 5 — Inflation annuelle observée à t+12 et prévisions des trois approches.

La courbe de la baseline suit une règle de persistance : elle prolonge le niveau d'inflation connu à la date d'origine. Cette règle fonctionne relativement bien lorsque l'inflation évolue progressivement. Elle devient moins performante lors des changements rapides de régime, notamment lorsque l'inflation accélère ou ralentit fortement.

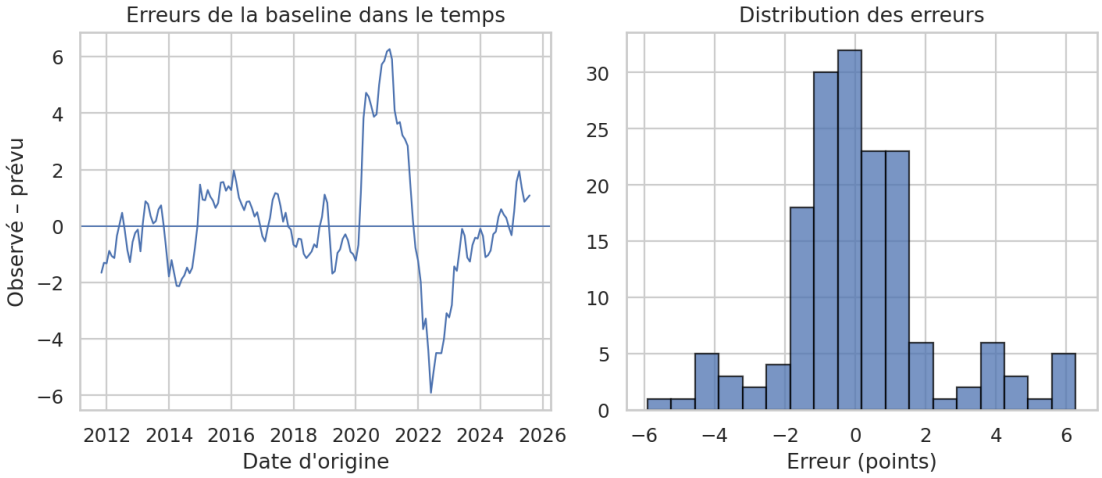


Figure 6 — Résidus de la baseline : erreur observée moins prévision.

Les erreurs les plus importantes se concentrent notamment autour de la période de forte accélération inflationniste de 2020–2021 et de la désinflation qui suit. Cela illustre la difficulté d'anticiper les ruptures avec une simple extrapolation du niveau courant.

7. Importance des variables et interprétation

L'importance par permutation est calculée sur le jeu de test pour le Gradient Boosting. Le principe consiste à mélanger une variable puis à mesurer la dégradation ou l'amélioration du score. Une valeur positive indique que le mélange détériore la performance ; une valeur négative signifie que le score s'améliore légèrement après permutation, ce qui suggère que la variable n'apporte pas de signal robuste dans ce modèle.

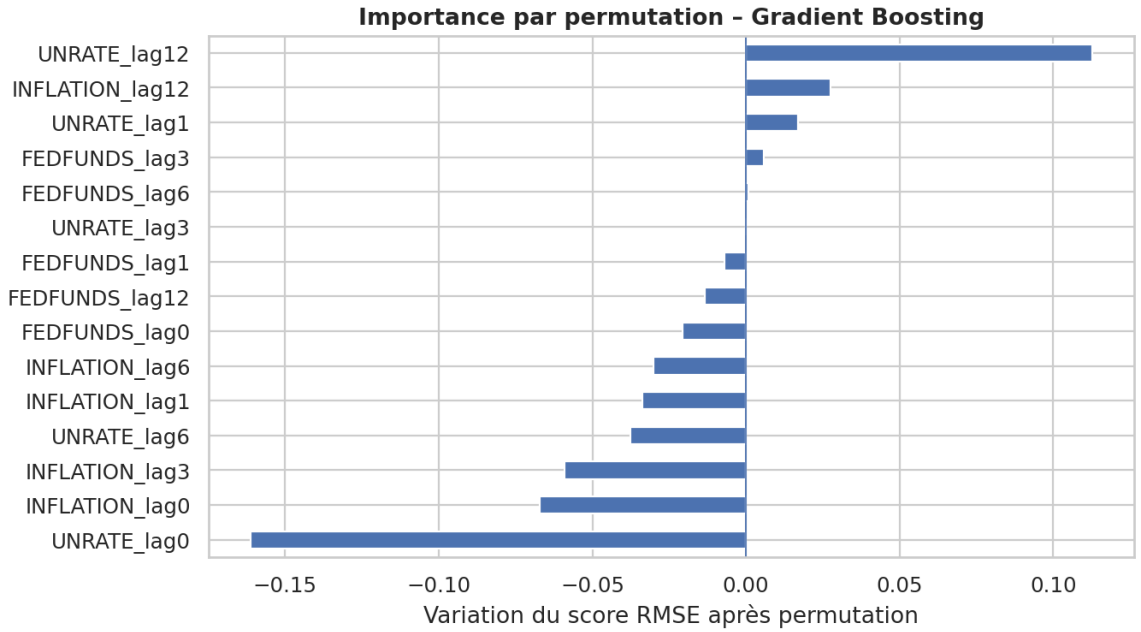


Figure 7 — Importance par permutation des quinze variables explicatives.

7.1. Principaux enseignements

Variable	Importance moyenne	Lecture prudente
UNRATE_lag12	0.1126	Contribution positive la plus élevée.
INFLATION_lag12	0.0277	Contribution positive, mais limitée.
UNRATE_lag1	0.0169	Contribution positive faible.
FEDFUNDS_lag3	0.0058	Contribution très faible.
FEDFUNDS_lag0	-0.0206	Importance négative dans cette évaluation.

Le chômage retardé de douze mois ressort comme la variable la plus utile au sein du Gradient Boosting. Toutefois, son importance reste modeste en valeur absolue et le modèle ne bat pas la baseline. Les retards du taux directeur n'apparaissent pas comme des facteurs déterminants dans cette spécification. Les importances négatives ne signifient pas que ces variables ont un effet économique négatif ; elles indiquent seulement que leur permutation n'a pas détérioré la performance mesurée.

Pour Ridge, les coefficients standardisés les plus élevés en valeur absolue sont associés à l'inflation courante, au taux directeur courant et au chômage courant. Ces coefficients décrivent les poids conditionnels du modèle linéaire, mais ne constituent pas des effets causaux.

8. Discussion économique : réponse à la problématique

Les résultats conduisent à une réponse nuancée. D'un côté, le chômage retardé de douze mois présente une importance positive dans le Gradient Boosting, ce qui suggère qu'il contient une information utile pour certaines prévisions. Le taux directeur apparaît également dans les variables du modèle, mais ses importances par permutation sont faibles ou négatives. D'un autre côté, cette information ne se traduit pas par une amélioration globale du RMSE par rapport à la baseline.

La meilleure performance de la dernière valeur connue souligne la forte persistance de l'inflation annuelle. Lorsque les variations de prix évoluent sans rupture majeure, l'inflation récente constitue déjà un point de départ difficile à dépasser. Les modèles plus complexes doivent apprendre des relations qui varient selon les régimes économiques et peuvent être perturbées par les chocs.

8.1. Résultats par sous-période

Période d'origine	N	Baseline RMSE	Ridge RMSE	Gradient Boosting RMSE
2011–2018	86	1.009	1.622	1.133
2019–2021	36	3.334	3.981	3.745
2022–2025	44	2.334	2.891	3.858

La baseline est la plus performante sur chacune des sous-périodes examinées. Les erreurs sont plus élevées sur 2019–2021, période comprenant des perturbations économiques exceptionnelles et une forte accélération de l'inflation future. Cette lecture confirme que les performances moyennes masquent des différences importantes selon les régimes.

8.2. Réponse indirecte

Ainsi, les indicateurs de chômage et de taux directeur peuvent apporter un signal complémentaire, mais les résultats de cette étude ne montrent pas qu'ils suffisent, dans leur forme actuelle, à améliorer la prévision de l'inflation à douze mois. La dynamique passée de l'inflation reste la référence la plus performante. Le chômage semble présenter un intérêt exploratoire, tandis que la contribution prédictive du taux directeur demeure limitée dans le modèle retenu.

9. Limites méthodologiques et pistes d'amélioration

9.1. Révisions des données et look-ahead bias

Les séries économiques sont susceptibles d'être révisées après leur première publication. Les fichiers FRED téléchargés aujourd'hui peuvent donc contenir des valeurs historiques qui n'étaient pas disponibles à la date à laquelle une prévision aurait été formulée. Le backtest peut ainsi bénéficier d'informations révisées a posteriori : c'est le biais d'anticipation (*look-ahead bias*).

Le découpage chronologique empêche de mélanger les observations futures et passées entre entraînement et test, mais il ne résout pas le problème des révisions historiques. Une simulation réellement « en temps réel » nécessiterait les millésimes de données disponibles à chaque date, notamment via ALFRED.

9.2. Vérification du calendrier mensuel

L'inspection des fichiers révèle une absence d'observation commune pour octobre 2025. Le notebook applique des décalages par nombre de lignes (‘shift(12)‘) ; après un mois manquant, douze lignes ne correspondent plus exactement à douze mois calendaires. Une vérification complémentaire a donc été effectuée en réindexant les séries sur un calendrier mensuel strict, puis en recalculant la cible et les retards.

Modèle	**RMSE notebook**	**RMSE avec calendrier mensuel strict**
Baseline	2,093	2.089
Ridge	2,649	2.646
Gradient Boosting	2,766	2.767

La correction du calendrier modifie légèrement les scores, mais ne change pas leur classement : la baseline reste la meilleure. Cette vérification renforce la robustesse de la conclusion principale, tout en montrant l'importance de vérifier l'alignement temporel.

9.3. Autres limites

- Les relations macroéconomiques peuvent changer selon les périodes et les régimes d'inflation.
- Le taux directeur est endogène aux décisions de politique monétaire : il réagit lui-même aux perspectives économiques.
- Les retards retenus sont fixés à l'avance ; une recherche systématique d'hyperparamètres pourrait modifier les performances.
- Les variables explicatives ne comprennent ni les prix de l'énergie, ni les anticipations d'inflation, ni les salaires, ni les taux de change.
- Les variables retardées sont corrélées entre elles ; les importances et coefficients doivent être interprétés avec prudence.

9.4. Améliorations possibles

- Utiliser les millésimes ALFRED pour reconstruire les informations réellement disponibles à chaque date.
- Tester plusieurs horizons (3, 6 et 12 mois) et plusieurs fenêtres d'estimation.
- Ajouter des indicateurs de prix de l'énergie, de salaires, de production et d'anticipations.
- Comparer les modèles à une baseline saisonnière ou à un modèle autorégressif spécialisé.

10. Conclusion générale

Ce projet a comparé trois approches de prévision de l'inflation annuelle américaine à un horizon de douze mois à partir de données mensuelles FRED. La démarche a combiné exploration des séries, construction d'une cible future, création de retards, validation chronologique et analyse de l'importance des variables.

Le résultat principal est que la prévision fondée sur la dernière valeur connue de l'inflation obtient le RMSE le plus faible sur l'échantillon test. Ridge et Gradient Boosting n'améliorent pas cette référence. L'analyse par permutation indique que le chômage retardé de douze mois est la variable la plus contributive du Gradient Boosting, mais cette contribution ne suffit pas à améliorer la performance globale. Le rôle prédictif du taux directeur apparaît limité dans la spécification étudiée.

La réponse à la problématique est donc prudente : le chômage et le taux directeur peuvent contenir des informations macroéconomiques pertinentes, mais leur apport prédictif supplémentaire n'est pas démontré par les performances hors échantillon obtenues ici. La persistance de l'inflation constitue une référence particulièrement forte. Enfin, les révisions des données et l'absence d'un mois dans le calendrier rappellent qu'une bonne prévision ne dépend pas seulement du choix de l'algorithme, mais aussi de la qualité et de la disponibilité réelle des informations.

Références et sources de données

- Federal Reserve Bank of St. Louis, FRED — CPIAUCSL : https://fred.stlouisfed.org/series/CPIAUCSL
- Federal Reserve Bank of St. Louis, FRED — UNRATE : https://fred.stlouisfed.org/series/UNRATE
- Federal Reserve Bank of St. Louis, FRED — FEDFUNDS : https://fred.stlouisfed.org/series/FEDFUNDS
- Federal Reserve Bank of St. Louis, ALFRED — archives des millésimes historiques : https://alfred.stlouisfed.org/
- Documentation scikit-learn — Ridge, GradientBoostingRegressor, TimeSeriesSplit et permutation importance : https://scikit-learn.org/stable/

Annexe — Paramètres principaux du notebook

Cible : inflation annuelle à t+12. Retards : 0, 1, 3, 6 et 12 mois. Découpage : 80 % entraînement / 20 % test, sans mélange aléatoire. Ridge : alpha = 10 avec standardisation. Gradient Boosting : 200 estimateurs, taux d'apprentissage 0,03, profondeur maximale 2, random_state = 42. Validation croisée : TimeSeriesSplit à cinq plis. Importance : permutation sur le jeu de test, 20 répétitions, random_state = 42.